

1 基于深度学习的辐射源识别

1.1 引言

辐射源识别算法需要可以准确区分出已知目标和未知目标，同时可以正确的对于已知目标进行分类。我们需要在未收集大量数据的前提下，可以迅速的识别出新的目标。与传统的利用已知类别的样本进行训练测试的机器学习算法不同，辐射源识别的问题是在 Open Set 的背景下，需要考虑输入未知分类样本的情况。由于复杂电磁环境下辐射源个体识别所面临的识别能力差等问题与挑战，传统辐射源识别方法具有很大的局限性，我们需要寻找一种新的方法解决该问题。

本章综合雷达信号处理、深度学习等多学科理论，详细分析不同辐射源雷达信号的差别，研究不同雷达的信号建模过程以及据此获取雷达信号的基本特征；综合考虑各种脉内细微特征，利用深度卷积神经网络与支持向量机进行结合，以雷达信号的模糊函数切片作为训练样本的特征向量，构建了一个可以对未知分类进行辨识的分类器。最后，利用实际数据进行验证，证明我们的分类器具有很高的准确性。

本章安排如下：4.2 节对辐射源信号进行了分析，并对其进行预处理，求取其模糊函数切片，4.3 节构建了本章的 Open Set 分类器，详细地阐述了深度卷积神经网络这个主分类器与支持向量机 Meta 分类器的设计过程，4.4 节利用实际数据对于分类器已知分类识别和未知分类辨别的性能进行了验证，4.5 节进行本章总结。

1.2 辐射源信号分析

对于辐射源信号的分析处理，本章主要考虑两方面：信号预处理、特征提取优化。本章所获得的信号为雷达辐射源的 I/Q 两路数据，这是一种在雷达信号处理领域常见的用来描述信号的方法。其中 I 表示 In-Phase，即同相，Q 表示 Quadrature，即正交，与 I 相位之差为 90 度。设需要表示的信号的峰值幅度为 A 、相位角为 ϕ ，则有：

$$I = A \cos \phi \quad (1-1)$$

$$Q = A \sin \phi \quad (1-2)$$

也即，可以利用公式 (1-3) 表示信号：

$$Ae^{i\phi} = A(\cos(\phi) + i \sin(\phi)) = I + Qi \quad (1-3)$$

从而可以根据公式 (1-1) 和公式 (1-2) 得到利用 I、Q 数据求取信号的峰值幅度和相位角的下式：

$$A = \sqrt{I^2 + Q^2} \quad (1-4)$$

$$\phi = \tan^{-1}(Q/I) \quad (1-5)$$

在完成信号形式的转换后，我们首先需要对信号进行初步的预处理，剔除无用和错误的数据。

在特征提取优化方面，合理的特征是分类识别的基础。由于存在相同型号的辐射源，利用简单的参数特征无法很好的完成辐射源的个体识别，但是在实际中辐射源自身存在相位噪声以及各类杂散输出，此部分特征可以用来区分出型号、参数均相同的辐射源，因此我们需要选取一种可以提取雷达辐射源这种无意调制产生的信号脉内细微特征的方法。模糊函数不仅能描述辐射源信号的分辨特性与模糊度，还能描述由雷达辐射源信号所决定的测量精度、杂波抑制特性等，通过模糊函数在时延和频偏这两个维度上的变换，可以多角度的刻画出无意调制对于发射信号的影响，因此我们最终选取了利用雷达模糊函数挖掘辐射源的特征。

1.2.1 模糊函数

对于信号 $x(t)$ ，其瞬时自相关函数为 $R_x(t, \tau) = x(t + \tau/2)x^*(t - \tau/2)$ ，其中 τ 为时延，模糊函数的定义为，

$$A(\tau, \nu) = \int_{-\infty}^{+\infty} R_x(t, \tau) e^{j2\pi\nu t} dt \quad (1-6)$$

即 $R_x(t, \tau)$ 关于时间 t 的傅里叶反变换。

为了方便在数字信号中使用，公式 (1-6) 可以经过变换等价于下面的形式：

$$A(\tau, \nu) = \int_0^\tau x(t)x^*(t + \tau)e^{j2\pi\nu t} dt \quad (1-7)$$

对信号均匀采样，即对接收信号和参考信号离散化后，公式 (1-7) 可以表示为：

$$A(\tau_l, \nu_m) = A(l, m) = \sum_{n=0}^{N-1} x(n)x^*(n+l)e^{\frac{j2\pi mn}{N}} \quad (1-8)$$

其中， $\tau_l = l/f_s$ 、 $\nu_m = mf_s/N$ 。

我们此处以一个简单的单载频矩形脉冲信号来展示模糊函数特征提取的作用，图 1-1 为模糊函数图，可以发现模糊函数存在一定的冗余，其主要变化均处于 0 时偏和 0 频偏附近。为了减小计算量，本章在频偏为 0 附近取不同时间延迟的切片作为信号特征，即可以有效地提取信号的相位噪声和杂散输出等个体特征，并且此处受噪声的干扰较小，更加稳定，图 1-2 即为在频偏为 0 处的单载频矩形脉冲信号模糊函数切片。

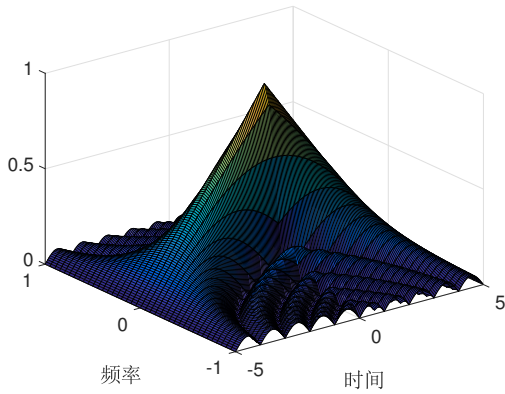


图 1-1 单载频矩形脉冲信号模糊函数图




图 1-2 单载频矩形脉冲信号模糊函数切片图

1.3 Open Set 分类器设计

通常的识别或者分类系统仅考虑的是一个闭集分类系统，然而在现实世界中，这种分类系统会遇到很大的问题。由于其最基本的假设是所有的类别均为先验已知，那么就会出现问題，例如在训练样本中不存在类别的样本就会被错误的分到某个类别中去。这种在训练的时候提供不完整的信息，而在测试的时候会添加未知分类的问题，称作 Open Set 识别^[1, 2]。这个问题还可以描述为需要在测试的时候拒绝未知样本。Open Set 目标识别系统必须可以准确的处理下面三种类型的数据类：

- 已知的（目标）类，被标记为正训练样本的数据。
- 已知的未知（非目标）类，被标记为负训练样本的数据。
- 未知的未知（非目标）类，在训练样本中不存在的类别的数据。

传统的机器学习算法均为针对于闭集数据设计的，随着识别算法应用场景的增多和对精度要求的提高，许多学者开始了对 Open Set 识别的研究。Simonson^[3] 提出了一种称作 *probabilistic fusion*(PF) 的利用统计的方法来进行 Open Set 识别，其主要通过合并来自不同数据源的证据得到一个统计测试模型，根据此模型的分布来对于类别进行判断。Scheirer 等人^[4] 提出了一种通过分析后验数据得分来进行类型判断的方法。

此部分主要解决的问题是当得到一个新的测试样本，如果该样本不属于已经经过训练的分类，那么传统的神经网络模型会将该样本指派给与其最相似的一个类别，此种情况对于一个 Open Set 识别系统，也即类似于辐射源识别系统这种具有较多尚未经过训练的样本的一个数据集，首先这会导致其识别率下降，另一方面是由于对于未知的辐射源无法很好的确定，无法很好的完成预警等任务。目前，学者对于该问题的研究主要分

为下面两个思路：

- 在训练集中添加一个“未知”类别，利用不同的来自非已知类别的数据作为训练样本对该类别进行训练，然后对于所有的输入数据进行类别的识别，对于识别结果为该类别的数据作为未知分类。
- 针对于多分类使用的 softmax 函数，可以设立阈值或者对于该识别结果进行一个评价（例如与已知类别数据的一个“距离”），通过这种方式分辨出未知分类。

第一个思路最大的问题是我们无法得到所有可能的未知类别的样本来进行训练，具有一定的局限性，不适用于我们这个具有大量来自未知分类数据的问题。针对于该问题，我们基于后一个思路设计了一个基于 Meta-Recognition 的可以识别未知辐射源的深度神经网络。首先是创建一个深度卷积神经网络分类器，该分类器的输出为该训练样本属于各个类别的概率，我们然后将此类别作为一个输入，输入到我们的 Meta-Recognition 中，这里我们设计一个支持向量机分类器作为 Meta-Recognition，然后从该 Meta-Recognition 会进行判断该输入是否为一个未知分类。

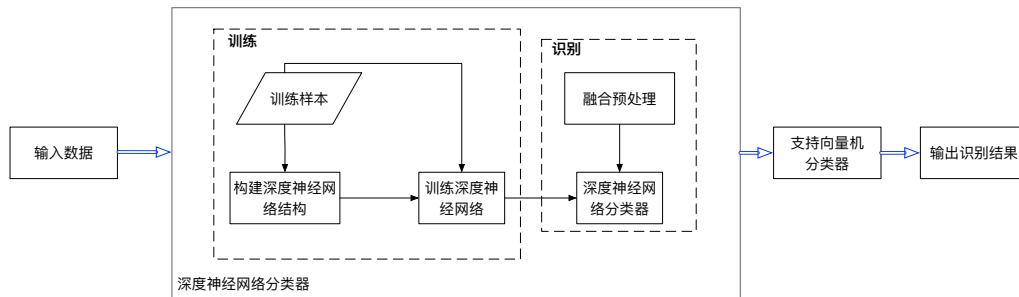


图 1-3 分类器设计结构图

1.3.1 深度卷积神经网络分类器设计

本章根据辐射源信号的实际数据以及其反映出来的特性，设计构建了一个具有 10 层的一维卷积神经网络。

该分类器作为主要分类器，且 Meta-Recognition 是以该分类器的输出作为输入，所以该分类器性能的好坏会直接影响到对已知类别的分类和对未知类别的判断。

第一层是输入层，由于模糊函数切片为一个 1×1000 的向量，因此输入层大小是 1×1000 。

第二层是卷积层 $C1$ ， $C1$ 对输入向量进行一维卷积运算提取特征，卷积运算可以最大程度的提取原始信号的特征。此处利用了 256 个大小为 1×3 的卷积滤波器，其窗口移动步长为 1。

第三层是一个池化层 $S2$ ， $S2$ 层对上一层 $C1$ 做池化处理，池化的目的是在保留数据有用信息的同时，尽可能减少数据量。此处采用的是 1×2 的最大池化操作。

第四层是一个卷积层 $C3$ ， $C3$ 对 $S2$ 的特征进行卷积操作，此处利用了 128 个大小为 1×3 的卷积滤波器。

第五层是一个卷积层 $C4$ ，其结构与 $C3$ 相同，128 个大小为 1×3 的卷积滤波器。

第六层是一个池化层 $S5$ ，其结构与 $S2$ 相同， 1×2 的最大池化操作。

第七层是一个卷积层 $C6$ ，其结构与 $C3$ 相同，128 个大小为 1×3 的卷积滤波器。

第八层是一个卷积层 $C7$ ，其结构与 $C3$ 相同，128 个大小为 1×3 的卷积滤波器。

第九层是一个池化层 $S8$ ，其结构与 $S2$ 相同， 1×2 的最大池化操作。

第十层是输出层，根据不同的类别个数选取相应的输出节点个数，首先将 $S8$ 的特征拉成一个一维向量，然后通过全连接网络与输出层进行连接，通过 Softmax 激活函数输出最终的结果。




图 1-4 深度卷积神经网络框架图

1.3.2 支持向量机 Meta-Recognition 设计

支持向量机原理

支持向量机是一种流行的分类方法，它可以在不需要大量数据的情况下产生良好的结果。对于一个二分类问题，设 $((x_1, y_1), \dots, (x_n, y_n))$ 为训练数据集，其中 x_i 为某样本的特征向量， $y_i \in \{-1, +1\}$ 为该样本的标签。支持向量机的思想为找到一个超平面将这些样本划分为正类（标签为 $+1$ ）和负类（标签为 -1 ），并且使得正类和负类之间的距离最大。这个超平面的间隔被定义为正类与负类之间的最近距离。

对于一个线性分类问题，假设所有的数据满足下面的约束：

$$w \cdot x_i + b \geq +1 \quad y_i = +1 \quad (1-9)$$

$$w \cdot x_i + b \leq -1 \quad y_i = -1 \quad (1-10)$$

其中 w 为超平面的法向量， $|b|/\|w\|$ 是从超平面到原点的垂直距离， $\|w\|$ 是向量 w 的

欧拉范数。将上述两个式子合并得到：

$$y_i(w \cdot x_i + b) \geq 1 \forall i \quad (1-11)$$

公式 (1-11) 中的训练样本构成了这个分类平面 (图 1-5 中的 H_1 与 H_2)。间隔 ρ 可以通过计算 H_1 与 H_2 的距离得到：

$$\rho = \frac{|1 - b|}{\|w\|} - \frac{|-1 - b|}{\|w\|} = \frac{2}{\|w\|} \quad (1-12)$$

因此求解标准分类超平面的最大间隔的问题，就转变为下面的优化问题。




图 1-5 标准分类平面，即具有最大间隔的超平面。画圆圈的样本组成了这个超平面，其被称作支持向量。

$$\min_{w \in \mathcal{H}} \tau(w) = \frac{1}{2} \|w\|^2 \quad s.t. \quad y_i(w \cdot x_i + b) \geq 1 \quad \forall i \quad (1-13)$$

为了使得约束更好表示，我们用拉格朗日优化算法对上式重新描述，

$$\min_{w, b} L(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^l \alpha_i y_i (x_i w + b) + \sum_{i=1}^l \alpha_i \quad (1-14)$$

其中 $\alpha_i \geq 0$ 为约束条件。

在实际计算过程中，我们通过对偶定义求解优化方程式 (1-14)，通过最大化方程式 (1-14) 相对于 α 来求取其相对于 w 和 b 的最小值。利用 Karush-Kuhn-Tucker 条件，则公式 (1-14) 变为下面对偶形式：

$$\max_{\alpha} L_D = \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j x_i \cdot x_j \quad s.t. \quad \forall i \begin{cases} \sum_i \alpha_i y_i = 0 \\ \alpha_i \geq 0 \end{cases} \quad (1-15)$$

因此，通过求解这个对偶优化问题，可以得到系数 α_i 。其中满足 $\alpha_i > 0$ 的解称作支持向量，他们位于标准分类平面 H_1 或者 H_2 上。注意到，仅有 $\alpha_i > 0$ 的解影响最终的支

持向量的选择。因此，可以得到决策函数：

$$f(x) = w^T x_i + b = \sum_{i=1}^M y_i \alpha_i (x_i^T x) + b \quad (1-16)$$

决策函数的符号取决于预测样本 x 。

此处我们讨论的情形的一个假设是，我们可以把所有的样本完全分为不同的类别。但是显然在大多数情况下，这种假设是不成立的。另外，这种假设也会导致过拟合现象的出现。因此，文献 [5] 提出了软间隔的支持向量机。其基本思想是，通过引入正的松弛变量 ξ_i 来放宽公式 (1-9) 和公式 (1-10) 的约束。基于此，得到公式 (1-17)

$$\forall i \quad \begin{cases} w \cdot x_i + b \geq +1 - \xi_i & y_i = +1 \\ w \cdot x_i + b \leq -1 - \xi_i & y_i = -1 \\ \xi_i \geq 0 \end{cases} \quad (1-17)$$

这允许一些样本在边缘内部，甚至在相反类别的情况下进一步交叉（见图 1-6）。虽然这种松弛使得支持向量机能够灵活地降低异常值的影响，但是从优化问题求解的角度来看，我们不希望有任意大的松弛变量 ξ_i ，因为这会导致 SVM 获得平凡和次优的解。因此，我们通过使松弛变量成为公式 (1-13) 的一部分，来限制松弛度：

$$\min_{w \in \mathcal{H}, \xi \in \mathbb{R}^m} \tau(w, \xi) = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m \xi_i \quad (1-18)$$

其约束条件为公式 (1-17)。超参数 $C > 0$ 是针对于误分类的惩罚系数，该系数需要根




图 1-6 软间隔支持向量机

据不同的分类任务和数据集进行调整。将其变为的对偶形式，则有

$$\max_{\alpha} L_D = \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j x_i \cdot x_j \quad s.t. \quad \forall i \quad \begin{cases} \sum_i \alpha_i y_i = 0 \\ C \leq \alpha_i \leq 0 \end{cases} \quad (1-19)$$

目前只是分析了线性支持向量机的问题，为了应对非线性分类问题，我们引入了核函数的概念。将训练数据通过某函数 $\Phi: \mathbb{R}^d \mapsto \mathcal{H}$ 。经过该变换后，我们只需要将原来计算 \mathbb{R}^d 的 $x_i \cdot x_j$ 变换为计算在 \mathcal{H} 域的向量积 $\Phi(x_i) \cdot \Phi(x_j)$ 。为了降低计算量，可以引入核函数 K 来避免数据 x_i 和 x_j 从 \mathbb{R}^d 映射到 \mathcal{H} 。

$$K(x_i, x_j) = \Phi(x_i) \cdot \Phi(x_j) \quad (1-20)$$

因此，可以将公式 (1-19) 变为下式：

$$\max_{\alpha} L_D = \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j K(x_i, x_j) \quad s.t. \quad \forall i \begin{cases} \sum_i \alpha_i y_i = 0 \\ C \leq \alpha_i \leq 0 \end{cases} \quad (1-21)$$

常用的核函数有下面几种：

- 线性核函数: $K(x, y) = \langle x, y \rangle$
- 多项式核函数: $K(x, y) = (\langle x, y \rangle)^d$
- RBF 核函数: $K(x, y) = \exp(-\frac{\|x-y\|^2}{2\sigma^2})$
- Sigmoid 核函数: $K(x, y) = \tanh(\gamma \langle x, y \rangle - \theta)$

支持向量机设计

我们可以利用所有的目标数据和未知目标的数据来作为训练样本对该 SVM 分类器进行训练，本部分我们以深度卷积神经网络的输出作为该分类器的输入，利用各类别的概率作为其特征进行训练识别。由于在类别的识别过程中，存在一定的波动性，这个会影响对于是否属于未知类别的分类判断，我们这里选取对于来自同一个辐射源的连续 10 拍的识别结果进行一个平均作为最终的输入。

下面是对于 SVM 分类器的设计，首先是核函数的选择。核函数将输入空间映射到高维特征空间，最终在高维特征空间中构造出最优分类超平面，从而把平面上本身不好分的非线性数据分开。常用的核函数为线性核函数和径向基核函数（Radial Basis Function, RBF）。对于核函数的选择，一般分为三种情况：

- 特征的数量很大，跟样本数量差不多，这时候选用逻辑回归算法或者是线性核的 SVM
- 特征的数量比较小，样本数量一般，不算大也不算小，选用径向基核函数
- 特征的数量比较小，而样本数量很多，需要手工添加一些特征变成第一种情况

由于我们的问题符合第二种情况，故选择径向基核函数。

具有径向基核的支持向量机具有两个关键参数，惩罚参数 C 的和核参数 σ ，这两个参数的取值在很大程度上决定了 SVM 的性能的优劣。核函数的参数主要影响样本数据在高维特征空间中分布的复杂程度，即维数。特征子空间的维数越高，那么得到的最优分类超平面就会越复杂。反之亦然。因此只有选择合适的核参数得到合适的特征子空间，才能得到推广能力良好的 SVM 分类器。大量的实验数据表明，如果与样本点之间的距离很小， $\sigma \rightarrow 0$ ；如果与样本点之间的距离很大时， $\sigma \rightarrow \infty$ ；当 σ 很小，径向基核函数支持向量机得到的判别函数差不多是一个常数，出现过拟合现象。当 σ 很大时，样本的正确分类率也会比较低。

惩罚参数是影响 SVM 算法性能的另一个重要因素。它的作用主要是调节特征子空间中 SVM 模型的置信范围与经验风险的比例，使支持向量机的泛化能力达到最好。特征子空间不同时，最优参数值取值也会不同。惩罚参数与经验误差的惩罚和 SVM 的复杂度成正比，与经验风险值成反比，反之亦然。因此，选择合适的惩罚参数也是非常重要的。

1.4 仿真实验与分析

1.4.1 实验环境

本章利用了来自 13 架民航飞机的气象雷达辐射源的数据，飞机信息参见下表 对于我们的气象雷达辐射源信号，原始的 I/Q 数据的示意图如图 1-7 所示




图 1-7 原始 I/Q 信号

原始的雷达信号为 I/Q 信号，我们将他们利用快速傅里叶变换求取其模糊函数切片作为输入的特征向量。每架飞机原始信号为 100 次雷达扫描周期的信号，为了增加数据样本数目，我们对原始信号添加噪声生成了新的信号，最终每架飞机均有 10000 组信

表 1-1 辐射源信号数据

飞机地址码	飞机航班号	飞机型号
7BF014	CCA1416	Airbus A330 (twin-jet)
780DB3	TBA9881	Airbus A330 (twin-jet)
780E06	CSN3438	Airbus A330 (twin-jet)
780EBB	CES293	Airbus A321 (twin-jet)
780EBF	CES2342	Airbus A320 (twin-jet)
7804F2	ZH9164	Airbus A320 (twin-jet)
7804F4	CES5856	Boeing 737
7806FC	CSN6402	Airbus A320 (twin-jet)
7808F0	CES5373	Airbus A319 (twin-jet)
78057F	CCA4103	Airbus A321 (twin-jet)
780063	CCA4377	Airbus A319 (twin-jet)
780375	CSC8253	Airbus A319 (twin-jet)
781022	EU2731	Airbus A319 (twin-jet)

号。对于这些信号，我们选择其中的 70% 作为训练样本，20% 用于交叉验证，10% 作为测试，同时在测试样本中添加与其等量的来自未训练类别也即未知类别的样本共同作为测试样本用来衡量其未知分类的识别率。

由于我们原始获得的数据为 I/Q 两路数据，为了更好的捕捉到回波的特征信息，我们对数据进行了一个变换，求取其模糊函数，并做偏移为 0 附近的一个切片。由于深度学习需要大量的数据进行训练学习，而本身数据量偏少，故我们在已有数据的基础上在一定信噪比的前提下，生成部分仿真数据。

对于数据的选择方面，我们从数据中选择出 2 至 8 个类别分别进行实验，对于每一个类别，我们均选择大约 10000 组数据，其中 70% 作为训练样本，20% 作为交叉验证样本，10% 作为测试样本，同时在测试样本中又添加了与已知分类等数量的未知分类的数据进行测试。由于该变换后，数据之间的差距比较大，我们对数据进行了归一化。我们采用的归一化方法为 min-max 标准化 (Min-Max Normalization)，也称为离差标准化，是对原始数据的线性变换，使结果值映射到 $[0, 1]$ 之间。转换函数如下：

$$x^* = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \quad (1-22)$$

其中 x_{\max} 为样本数据的最大值， x_{\min} 为样本数据的最小值。




图 1-8 不同类别样本特征图

我们采用网格搜索法对 SVM 参数进行调优，最终选择参数惩罚参数为 32，核参数 σ 为 0.0312。

1.4.2 实验结果分析

深度卷积神经网络识别结果

首先验证深度卷积算法的识别正确率，利用 8 个类别的数据进行训练和测试，迭代次数为 100 次。




图 1-9 迭代次数与识别准确率曲线图




图 1-10 迭代次数与损失函数曲线图

对于具有 8 个类别的数据，我们对于迭代次数与识别准确率进行了验证，其结果如图 1-9 所示。

Open Set 分类器识别结果

在上述样本的情形下，我们通过选取不同的类别数目，进行训练和测试得到表 1-4 的识别结果。从表中数据我们可以看出，随着样本类别数的增加，对于未知分类的识别准

表 1-2 深度卷积神经网络分类结果

	类别 A	类别 B	类别 C	类别 D	类别 E	类别 F	类别 G	类别 H
类别 A	100%	0	0	0	0	0	0	0
类别 B	7.42%	92.58%	0	0	0.13	0	0	0
类别 C	0	0	97.83%	0	0	2.17%	0	0
类别 D	0	0	3%	97%	0	0	0	0
类别 E	0	0	0	0	100%	0	0	0
类别 F	0	0	0.08%	0	0	99.92%	0	0
类别 G	0	0	1.08%	0	0	0	98.92%	0
类别 H	1.63%	0	0	0	0	0.63	0	98.37%

确率也随之有了大幅度的增加，而另一方面随着类别的增加，对于每个类别的识别准确率仍然维持在比较高的水平。

1.5 小结

本章针对复杂电磁环境下辐射源的识别面临的电磁信号干扰大、雷达信号参数相近等问题与挑战，利用深度学习的思想与方法，深入研究辐射源脉内细微特征，设计合适的神经网络结构，并基于民航机载气象雷达数据进行初步验证。主要特色与创新点如下：

(1) 利用深度学习方法进行辐射源识别前沿。通过对现有辐射源信号进行分析，利用其脉内细微特征作为训练样本，使得识别准确率有了较大的进步。虽然已有研究利用神经网络、支持向量机等机器学习算法进行识别，但是仍然需要基于雷达信号的基本参数，没有考虑信号的内部特征参数。

(2) 本章采用方法具有较强的抗噪声、抗干扰能力以及较好的鲁棒性。传统方法进行辐射源个体识别前均需进行降噪、多径抑制和分选等复杂的信号预处理工作，这些操作会在一定程度上削弱雷达的个体特征。深度学习方法可以通过大量的样本，智能地判断各特征的权重，通过赋予不同的权重在保留雷达个体特征的情况下，避免干扰的影响。

(3) 本章设计了 meta 识别器，实现了对辐射源中未知分类的辨别。

表 1-3 深度卷积神经网络分类结果

迭代次数	训练样本集学习正确率	测试样本集学习正确率	学习时间 (s)
1	0.4670	0.5782	1.0931×10^3
2	0.7658	0.7758	2.3572×10^3
10	0.9414	0.8102	1.1444×10^4
20	0.9709	0.9065	2.1370×10^4
40	0.9819	0.9883	4.3181×10^4
50	0.9839	0.9830	5.3437×10^4
60	0.9866	0.9746	6.4143×10^4
70	0.9903	0.9904	7.4849×10^4
80	0.9904	0.9798	8.5597×10^4
90	0.9908	0.9872	9.6328×10^4
100	0.9902	0.9811	1.0711×10^5

表 1-4 不同已知类别个数数据识别结果

已知类别数目	已知类别识别正确率	未知类别分辨正确率
2	99.55%	84.32%
3	99.59%	93.10%
4	99.00%	97.81%
5	99.75%	98.42%
6	98.63%	98.85%
7	99.28%	99.22%
8	97.86%	99.14%

参考文献

- [1] Scheirer WJ et al. Toward open set recognition[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence. 2013, 35(7):1757–1772.
- [2] Jain LP, Scheirer WJ, Boulton TE. Multi-class open set recognition using probability of inclusion[C]. In European Conference on Computer Vision. Springer2014:393–409.
- [3] Simonson K. Probabilistic fusion of ATR results[R]. Tech. rep.Sandia National Laboratories (SNL-NM), Albuquerque, NM1998.
- [4] Scheirer WJ et al. Meta-recognition: The theory and practice of recognition score analysis[J]. IEEE transactions on pattern analysis and machine intelligence. 2011, 33(8):1689–1695.
- [5] Cortes C, Vapnik V. Support-vector networks[J]. Machine learning. 1995, 20(3):273–297.